

Dự báo chuỗi thời gian bán lẻ có xét đến tình trạng hết hàng

Two-stage latent demand recovery + daily demand forecasting trên FreshRetailNet-50K

Nhóm 3

Mục lục trình bày

- 1 Introduction
- 2 Dataset & EDA
- 3 Methodology
- 4 Forecasting Results
- 5 Model Evaluation
- 6 Business Insights
- 7 Conclusion
- 8 Future Work

Thông điệp chính

Với dữ liệu bán lẻ có stockout, forecast trực tiếp observed sales dễ học sai nhu cầu. Đề án xử lý bằng pipeline two-stage: recover latent demand theo giờ, rồi forecast daily next-7-day demand.

1. Introduction: bài toán không chỉ là forecast sales

Vấn đề cốt lõi

Observed sales có thể bị **censor** bởi stockout: bán thấp không chắc là nhu cầu thấp, mà có thể là cửa hàng không còn hàng để bán.

Nếu forecast trực tiếp observed sales

- Model học cả nhu cầu thật lẫn giới hạn tồn kho.
- Dễ under-forecast ở nhóm hay hết hàng.
- Vòng lặp xấu: dự báo thấp → nhập ít → tiếp tục stockout.

Hướng của đề án

- Recover latent demand ở các giờ stockout.
- Aggregate hourly recovered demand lên daily.
- Forecast tổng demand 7 ngày tiếp theo.

Câu hỏi nghiên cứu và contribution

- 1 Có thể recover demand bị che trong stockout mà không leakage thời gian không?
- 2 Imputation có làm tổng demand tăng quá mức không?
- 3 Forecast trên recovered demand có tốt hơn forecast trên observed sales không?
- 4 Các kết quả này chuyển thành insight vận hành như thế nào?

Đóng góp kỹ thuật

- Expanding-window recovery.
- Calibration + cap q90.
- Pseudo-stockout validation.
- Hybrid seasonal-ML.

Đóng góp business

- Ước lượng lost sales.
- Giữ weekly seasonality làm baseline vận hành.
- Đề xuất workflow replenishment có uncertainty.

2. Dataset: FreshRetailNet-50K sample


Sample fraction	10.00%
Hourly rows	11,640,000
Series	5,000
Stores	866
Products	516
Stockout row rate	24.65%

- Daily rows chứa `hours_sale` và `hours_stock_status`.
- Disaggregate daily → hourly để xử lý stockout đúng cấp.

Quy trình dữ liệu và tiền xử lý



EDA: stockout là vấn đề trung tâm




Hàm ý

- Stockout rate khoảng 24.65%.
- Đây không phải nhiễu nhỏ để bỏ qua.
- Observed sales cần được đọc là dữ liệu có thể bị kiểm duyệt.


Framing

Target cuối không phải raw sales, mà là recovered demand proxy có kiểm soát.

EDA: dữ liệu thừa, lệch và có mùa vụ





- Nhiều zero, spike và phân phối lệch.
- WAPE phù hợp hơn MAPE.



- Weekly seasonality rõ.
- Seasonal naive 7-day là benchmark bắt buộc.

ACF/PACF và spectrum dùng để làm gì?



Cách dùng trong bài

Không dùng ACF/PACF để ép chọn ARIMA. Dùng chúng để biện minh lag/rolling/seasonal features và baseline mùa vụ.

Tại sao không chọn classical time series làm model chính?

ARIMA/SARIMA từng chuỗi

- Khó scale cho 5.000 series sample, 50.000 series full.
- Không ổn với chuỗi thưa, zero-inflated.
- Khó đưa stockout, promotion, weather, category.

Deep learning

- Có thể dùng nhưng cần tuning/tài nguyên lớn.
- Rủi ro khó bảo vệ nếu validation chưa cực chặt.
- Đồ án ưu tiên pipeline rõ, nhẹ, tái lập.

Lựa chọn chính

LightGBM global model + seasonal baseline: cân bằng giữa hiệu suất, tốc độ, giải thích và tính tái lập.

3. Methodology: two-stage framework

Quy trình stockout-aware latent demand recovery và forecasting



Nguyên tắc: chỉ dùng dữ liệu quá khứ để recover block hiện tại; validation/test không được dùng để fit recovery model.


Expanding-window recovery chống leakage

- Warm-up 14 ngày để có đủ hai chu kỳ tuần.
- Mỗi block 7 ngày chỉ học từ non-stockout rows trong quá khứ.
- Validation/test recovery chỉ dùng model fit từ train-period.
- Calibration cũng lấy từ train-period out-of-fold rows.

Nguyên tắc

Không dùng ngày tương lai để recover nhu cầu của ngày quá khứ.

Quy trình xử lý riêng cho expanding-window recovery



Mỗi block chỉ nhìn về quá khứ: không dùng ngày phía sau để recover ngày phía trước: validation/test không được dùng để fit recovery model.


Feature engineering: không chỉ lag của chính series

Nhóm feature chính

- Calendar: hour, day-of-week, month.
- Lag/rolling: 1, 7, 14, 28 ngày; 24/168 giờ.
- Stockout: flag, rate, rolling stockout.
- Promotion/weather/category/store/product.

Hai điểm mù được bổ sung

- Velocity/momentum: bán nhanh trước stockout.
- Peer/substitution: sản phẩm cùng store/category.
- Mục tiêu: cho recovery nhìn thêm bối cảnh xung quanh stockout.



Imputation control: không để recovery phóng đại demand

Observed sales	482,697.09
Recovered demand	539,898.12
Recovered lost demand	57,201.70
Lift	11.85%
Calibration factor	1.0110
Cap q90	0.0729

Công thức


Raw impute → calibration → positive lost demand → cap q90 → recovered demand.

- q90 giữ khoảng 78.88% raw lost demand.
- q100 lift lên 15.02% nhưng rủi ro over-imputation.

Pseudo-stockout validation và sensitivity

Pseudo-stockout validation

- Dùng non-stockout rows trong validation làm “đáp án giả”.
- Daily aggregate WAPE: 16.56%.
- Prediction/actual ratio: 1.1152.
- Recovery còn hơi over-predict, nên cần cap.



4. Forecasting setup

Target

- Hourly recovered demand $\rightarrow$ daily demand.
- Forecast origin ngày t .
- Target: tổng demand từ $t + 1$ đến $t + 7$.

Models

- Naive x7.
- Seasonal naive 7-day.
- Observed-sales LightGBM.
- Recovered-demand LightGBM.
- Hybrid seasonal-ML.


Evaluation

So sánh trên recovered latent demand proxy để trả lời đúng câu hỏi: forecast demand đã giảm bias do stockout.

Forecasting results: hybrid tốt nhất nhưng seasonal naive rất mạnh

Model	WAPE	WPE
Naive x7	31.46%	-2.00%
Seasonal naive	19.85%	-6.12%
Observed LGBM	24.92%	-18.74%
Recovered LGBM	20.19%	-7.84%
Hybrid	19.62%	-7.15%

- Hybrid giảm WAPE 21.27% so với observed-sales LGBM.



Hybrid seasonal-ML là gì?

Công thức kết hợp

$$\hat{y}_{hybrid} = \alpha \hat{y}_{LightGBM} + (1 - \alpha) \hat{y}_{SeasonalNaive}$$

Trọng số chọn bằng validation

- LightGBM weight: 60%.
- Seasonal naive weight: 40%.
- Không chọn bằng test set.

Tại sao hợp lý?


- Seasonal naive giữ pattern tuần.
- LightGBM hiệu chỉnh theo stockout, lag, product/store.
- Giảm rủi ro ML học quá phức tạp nhưng thua baseline.

Feature importance: mô hình học gì?


- `stockout_rate` là feature quan trọng nhất.
- Lag 7/14/28 ngày xác nhận weekly pattern.
- Rolling mean/sum giúp ổn định chuỗi thưa.

Diễn giải

Model không chỉ dựa vào trend gần nhất; nó kết hợp stockout, seasonality và lịch sử demand đã recover.




5. Model evaluation: residual diagnostics



- Hybrid Ljung–Box p-value: 0.0288.
- Residual chưa hoàn toàn white noise.
- Một phần do target next-7-day bị overlap.
- Kết luận trung thực: model cải thiện forecast nhưng chưa học hết pattern.


Prediction intervals: forecast không phải một con số chắc chắn



Hybrid 80% coverage	76.77%
Hybrid 95% coverage	93.89%
Mean 80% width	4.43
Mean 95% width	9.78

- 80% interval hơi hẹp.
- 95% interval phù hợp hơn nhưng rộng hơn.
- Dùng để chọn safety stock theo rủi ro.

6. Business insights: lost sales và ưu tiên vận hành



Insight

- Recovered lost demand: 57,201.70.
- Lift over observed: 11.85%.
- Không phải mọi stockout quan trọng như nhau.
- Ưu tiên series có uplift/lost demand cao.

Hành động

Kiểm tra safety stock, lead time, tần suất bổ sung và chất lượng ghi nhận stock status ở nhóm uplift cao.

Ứng dụng vào replenishment

Bước	Đầu vào	Đầu ra vận hành
Recovery	Hourly sales + stockout	Recovered demand proxy
Forecast	Daily recovered demand	Next-7-day demand
Quy đổi nhập hàng	Forecast + tồn kho + lead time	Đề xuất lượng nhập
Theo dõi	Actual + stockout + error	Cảnh báo bias/drift

Nếu chi phí stockout cao

- Dùng forecast gần upper interval.
- Tăng safety stock cho nhóm uplift cao.

Nếu hàng dễ hư hỏng

- Dùng point forecast hoặc interval thấp hơn.
- Tăng tần suất cập nhật forecast.

7. Conclusion

- 1 Stockout làm observed sales đánh giá thấp demand, nên cần recovery trước forecast.
- 2 Expanding-window recovery giúp tránh leakage theo thời gian.
- 3 Recovered demand lift khoảng 11.85% so với observed sales.
- 4 Forecast trên recovered demand tốt hơn forecast trực tiếp observed sales.
- 5 Hybrid seasonal-ML đạt WAPE 19.62% và giữ được weekly pattern mạnh.

Câu chốt

Điểm mạnh của đề án là pipeline có kiểm soát: đúng framing, có benchmark mạnh, có diagnostics, có uncertainty và có business interpretation.

Limitations: nói rõ để bảo vệ tốt hơn

- Recovered demand là proxy, không phải ground truth tuyệt đối.
- Pseudo-stockout validation còn over-predict nhẹ.
- Residual chưa white noise hoàn toàn.
- Peer/substitution mới ở mức feature đơn giản.
- Sample 10% có thể chưa phản ánh đầy đủ toàn bộ network sản phẩm.
- Chưa triển khai deep imputation do phạm vi và tài nguyên đồ án.

Tinh thần trình bày

Không giấu vấn đề; dùng diagnostics để biết mô hình còn sai ở đâu và vì sao.

8. Future work

Kỹ thuật

- Deep imputation: SAITS, CSDI, TimesNet, ImputeFormer.
- Product substitution graph.
- Quantile/conformal forecasting.
- Rolling retraining và drift monitoring.

Business evaluation

- Giảm stockout rate.
- Giảm lost sales proxy.
- Kiểm soát hàng hủy/tồn kho dư.
- A/B test theo store/category.

Nguyên tắc mở rộng

Model phức tạp hơn chỉ đáng dùng nếu vượt seasonal baseline và giữ được validation chống leakage.

Cảm ơn thầy và các bạn đã lắng nghe!

Q&A

Một câu nhớ nhất

Forecast tốt trong bài này không bắt đầu từ model phức tạp, mà bắt đầu từ việc hiểu đúng observed sales bị stockout censor.