

Dự báo chuỗi thời gian bán lẻ có xét đến tình trạng hết hàng trên FreshRetailNet-50K

Abstract

Báo cáo này trình bày một quy trình two-stage cho bộ dữ liệu FreshRetailNet-50K: khôi phục latent demand trong các giờ stockout, sau đó dự báo nhu cầu trên recovered demand. Thí nghiệm sử dụng mẫu 0.1 ở cấp `series_id`, giữ nguyên toàn bộ dòng thời gian của các chuỗi được chọn. Dữ liệu theo ngày được bung thành dữ liệu theo giờ bằng `hours_sale` và `hours_stock_status`, rồi aggregate lại thành daily recovered demand cho bài toán dự báo tổng nhu cầu 7 ngày. Tập dữ liệu cuối cùng có 11640000 quan sát theo giờ và 5000 chuỗi, từ 2024-03-28 00:00:00 đến 2024-07-02 23:00:00.

1 Câu hỏi nghiên cứu và động lực

Bài toán đặt ra là dự báo lượng bán trong tương lai cho nhiều chuỗi cửa hàng–sản phẩm, đồng thời xét đến tình trạng hết hàng. Trong bán lẻ, doanh số quan sát được trong lúc hết hàng thường bị kiểm duyệt: bán thấp không nhất thiết là nhu cầu thấp, mà có thể do không còn hàng để bán. Vì vậy, mô hình cần tận dụng thông tin mùa vụ, lịch, khuyến mãi, thời tiết và đặc biệt là đặc trưng stockout-aware.

2 Dữ liệu và tiền xử lý

Dữ liệu gốc gồm `train.parquet` và `eval.parquet`. Sau khi chuẩn hóa, biến `series_id` được tạo từ `city_id`, `store_id` và `product_id`. Các chuỗi bán theo giờ trong `hours_sale` được bung thành từng quan sát giờ; trạng thái hết hàng theo giờ được lấy từ `hours_stock_status`.

Table 1: Tóm tắt chất lượng dữ liệu

Metric	Value
Sample fraction	0.1
Number of rows	11640000
Number of series	5000
Number of stores	866
Number of products	516
Number of cities	18
Start date	2024-03-28 00:00:00
End date	2024-07-02 23:00:00
Frequency	Hourly rows expanded from hours_sale and hours_stock_status
Missing dt count	0
Duplicate rows	0
Missing sale_amount	0
Stockout rate	0.24667061855670103
Average sale_amount	0.04194150120019913
Median sale_amount	0.0

3 Phân tích khám phá dữ liệu

Các biểu đồ EDA cho thấy dữ liệu có tính mùa vụ theo giờ, tính thưa cao, và tỷ lệ hết hàng biến động rõ theo thời gian.




Figure 1: Tổng lượng bán theo giờ theo thời gian.




Figure 2: Tỷ lệ hết hàng theo giờ theo thời gian.




Figure 3: Phân phối lượng bán theo giờ.




Figure 4: Phân phối log1p của lượng bán theo giờ.




Figure 5: Lượng bán trung bình theo giờ trong ngày.




Figure 6: Lượng bán trung bình theo thứ trong tuần.

Table 2: Các chuỗi đại diện được chọn để minh họa

series_id	type	total_sales	stockout_rate	n_obs
4_11_267	high_volume	1,896	0.6070	2328
3_793_550	intermittent	49.7000	0.1907	2328
5_6_757	stockout_heavy	48.4000	0.7371	2328




Figure 7: Chuỗi đại diện có tổng lượng bán cao.




Figure 8: Chuỗi đại diện có nhu cầu thưa/ngắt quãng.




Figure 9: Chuỗi đại diện có tỷ lệ hết hàng cao.

4 Tính dừng, ACF/PACF và nhận dạng mô hình

ADF và KPSS được dùng để kiểm tra tính dừng trên chuỗi tổng hợp và các chuỗi đại diện. Kết quả cho thấy sai phân bậc một và sai phân mùa vụ lag 24 giúp cải thiện tính dừng, phù hợp với việc sử dụng các đặc trưng lag 24 giờ và lag 168 giờ.

Table 3: Kết quả kiểm định ADF/KPSS

Series	Transformation	ADF p-value	KPSS p-value	Conclusion	N
aggregate_hourly_sales	original	0.0000	0.0100	mixed evidence	2328
aggregate_hourly_sales	log1p	0.0000	0.0100	mixed evidence	2328
aggregate_hourly_sales	first_difference	0.0000	0.1000	stationary	2327
aggregate_hourly_sales	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
high_volume_series	original	0.3070	0.0100	non-stationary	2328
high_volume_series	log1p	0.4265	0.0100	non-stationary	2328
high_volume_series	first_difference	0.0000	0.1000	stationary	2327
high_volume_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
intermittent_series	original	0.0000	0.1000	stationary	2328
intermittent_series	log1p	0.0000	0.1000	stationary	2328
intermittent_series	first_difference	0.0000	0.1000	stationary	2327
intermittent_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
stockout_heavy_series	original	0.0058	0.0100	mixed evidence	2328
stockout_heavy_series	log1p	0.0031	0.0100	mixed evidence	2328
stockout_heavy_series	first_difference	0.0000	0.1000	stationary	2327
stockout_heavy_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304




Figure 10: ACF của chuỗi tổng hợp theo giờ.




Figure 11: PACF của chuỗi tổng hợp theo giờ.

4.1 Phân tích phổ tần số

Ngoài ACF/PACF, báo cáo dùng periodogram để kiểm tra seasonality trong miền tần số. Mục tiêu là xác nhận liệu các chu kỳ được dùng trong feature engineering và baseline có xuất hiện rõ trong dữ liệu hay không. Với chuỗi hourly aggregate, peak mạnh nhất nằm ở khoảng 24 giờ, ủng hộ việc dùng lag 24 giờ và các đặc trưng theo giờ trong ngày. Một peak yếu hơn gần 168 giờ cũng xuất hiện, phù hợp với seasonality theo tuần. Sau khi chuyển sang daily recovered demand, peak lớn nhất nằm gần 7 ngày, cũng có lựa chọn lag 7/14/28 ngày và seasonal naive theo tuần cho bài toán two-stage.




Figure 12: Phổ tần số của aggregate observed sales theo giờ.

Table 4: Các peak chu kỳ lớn nhất của hourly aggregate sales

Rank	Period	Frequency	Power	Period unit
1	24.0000	0.0417	0.6365	hours
2	8.0000	0.1250	0.1182	hours
3	12.0000	0.0833	0.0559	hours
4	6.0000	0.1667	0.0325	hours
5	164.5714	0.0061	0.0106	hours
6	28.0976	0.0356	0.0099	hours
7	12.9438	0.0773	0.0058	hours
8	20.9455	0.0477	0.0053	hours




Figure 13: Phổ tần số của daily recovered demand.

Table 5: Các peak chu kỳ lớn nhất của daily recovered demand

Rank	Period	Frequency	Power	Period unit
1	6.8462	0.1461	0.2108	days
2	3.5600	0.2809	0.0679	days
3	4.4500	0.2247	0.0232	days
4	2.3421	0.4270	0.0169	days
5	5.9333	0.1685	0.0169	days
6	5.2353	0.1910	0.0118	days
7	2.1190	0.4719	0.0100	days
8	9.8889	0.1011	0.0081	days

5 Thiết kế đặc trưng và chia tập dữ liệu

Các đặc trưng được tạo gồm calendar features, lag features, rolling features, promotion/weather features và stockout-aware features. Để tránh rò rỉ dữ liệu, tất cả rolling features đều được shift một bước trước khi tính rolling. Mục tiêu dự báo là `target_h1` và `target_h24`, tương ứng với dự báo trước 1 giờ và 24 giờ.

Table 6: Chia train/validation/test theo thời gian

Split	Start date	End date	Rows	Series
Train	2024-03-28	2024-06-10 23:00:00	9000000	5000
Validation	2024-06-11	2024-06-17 23:00:00	840000	5000
Test	2024-06-18	2024-07-01 23:00:00	1680000	5000

Với pipeline two-stage, phần forecasting cuối cùng được định nghĩa ở cấp ngày theo **forecast origin**. Mỗi dòng dự báo tại ngày t có target là tổng recovered demand trong 7 ngày sau đó, tức từ $t + 1$ đến $t + 7$. Vì vậy, báo cáo lưu thêm bảng split riêng cho daily forecasting để phân biệt rõ origin window và target window.

Table 7: Chia tập cho daily 7-day forecasting theo forecast origin

Split	Origin start	Origin end	Target window start	Target window end	Rows	Series
Train	2024-03-28	2024-06-03	2024-03-29	2024-06-10	340000	5000
Validation	2024-06-04	2024-06-10	2024-06-05	2024-06-17	35000	5000
Test	2024-06-11	2024-06-24	2024-06-12	2024-07-01	70000	5000

6 Lý do lựa chọn mô hình

Mô hình chính được chọn là LightGBM vì bài toán có nhiều chuỗi store-product, dữ liệu thưa, nhiều biến ngoại sinh và nhiều đặc trưng phi tuyến. Huấn luyện một mô hình ARIMA/SARIMA riêng cho từng chuỗi sẽ khó mở rộng, không ổn định với chuỗi thưa và khó đưa đầy đủ thông tin khuyến mãi, thời tiết, stockout. Ridge được giữ lại như baseline tuyến tính để diễn giải. SARIMAX được dùng trên chuỗi tổng hợp như một đối chứng cổ điển, nhưng không thay thế cho mô hình toàn cục ở cấp sản phẩm-cửa hàng. Deep learning không được chọn làm mô hình chính vì yêu cầu nhiều tài nguyên và tuning hơn, trong khi LightGBM cho tỉ lệ hiệu quả/độ phức tạp tốt hơn trong bối cảnh đồ án tái lập được.

7 Tiếp cận theo hướng của paper/repository

Paper FreshRetailNet-50K và repository baseline không xem đây chỉ là bài toán dự báo doanh số quan sát được. Hướng tiếp cận chính là two-stage censored demand modeling:

1. Khôi phục latent demand trong các giờ stockout vì observed sales bị kiểm duyệt.
2. Dùng recovered demand để huấn luyện mô hình dự báo nhu cầu robust hơn.


Trong đồ án này, ta triển khai một phiên bản nhẹ và tái lập được của ý tưởng đó. Để tránh leakage theo thời gian, phần recovery trong train period dùng expanding window theo block tuần: mỗi block chỉ được recover bằng mô hình học từ các giờ không stockout trong quá khứ. Validation và test được recover bằng final recovery model train trên các giờ không stockout thuộc train period. Với các giờ stockout, mô hình tạo imputed_demand_raw, sau đó hiệu chỉnh bằng calibration factor học từ validation non-stockout rows. Phần lost demand được tính bằng $\max(\text{calibrated imputed demand} - \text{observed sales}, 0)$ và được cap tại phân vị q90 của lost demand dương để tránh một số giờ stockout làm tổng demand tăng quá mức. Cuối

cùng, $\text{recovered_demand} = \text{observed sales} + \text{capped lost demand}$. Sau đó recovered demand theo giờ được aggregate thành daily demand để làm bài toán dự báo tổng nhu cầu 7 ngày tiếp theo.

7.1 Cơ chế expanding-window recovery

Quy trình recovery được thiết kế theo nguyên tắc point-in-time: tại một thời điểm bất kỳ, mô hình không được sử dụng dữ liệu ở tương lai để khôi phục demand ở hiện tại. Sơ đồ dưới đây tóm tắt toàn bộ luồng xử lý từ dữ liệu gốc đến latent demand recovery và forecasting.

Quy trình stockout-aware latent demand recovery và forecasting




Nguyên tắc: chỉ dùng dữ liệu quá khứ để recover block hiện tại; validation/test không được dùng để fit recovery model.

Figure 14: Sơ đồ quy trình expanding-window latent demand recovery và forecasting.

7.1.1 Quy trình xử lý riêng cho expanding-window recovery

Phần recovery được tách thành một quy trình riêng vì đây là bước dễ gây leakage nhất trong bài toán latent demand. Ý tưởng cốt lõi là mô phỏng đúng bối cảnh triển khai thực tế: khi cần khôi phục nhu cầu ở tuần hiện tại, mô hình chỉ được biết các quan sát không stockout đã xảy ra trước tuần đó. Do đó, ngay cả trong train period, ta không dùng dữ liệu của các ngày phía sau để recover các ngày phía trước.

Quy trình xử lý riêng cho expanding-window recovery



Mỗi block chỉ nhìn về quá khứ: không dùng ngày phía sau để recover ngày phía trước; validation/test không được dùng để fit recovery model.

Figure 15: Quy trình xử lý riêng cho expanding-window latent demand recovery.

Quy trình chi tiết gồm các bước:

1. **Sắp xếp dữ liệu theo thời gian:** toàn bộ hourly frame được sort theo dt, sau đó chia train/validation/test theo mốc thời gian cố định.
2. **Giữ warmup 14 ngày đầu:** giai đoạn này chưa đủ lịch sử để fit recovery model ổn định nên `recovered_demand` được đặt bằng `observed sales`.

3. **Tạo block recovery trong train period:** phần train sau warmup được chia thành các block 7 ngày liên tiếp.
4. **Fit model theo nguyên tắc quá khứ:** với block thứ k , tập train của recovery model chỉ gồm các dòng có $dt < block_start$ và $stockout_flag = 0$.
5. **Recover block hiện tại:** model dự đoán $imputed_demand$ cho block k ; với dòng stockout, ta chỉ cộng thêm phần lost demand dương sau calibration và cap, nên nhu cầu recovered không thấp hơn doanh số đã bán thật nhưng cũng không bị phóng đại bởi các dự đoán cực trị.
6. **Di chuyển cửa sổ:** sau khi xử lý xong block k , block này trở thành quá khứ cho block $k + 1$, nhưng chỉ các dòng non-stockout mới được dùng để fit các model sau.

Sau khi train period kết thúc, một final recovery model được fit trên toàn bộ non-stockout rows của train period và chỉ dùng để recover validation/test. Cách này giữ đúng point-in-time constraint: validation/test không tham gia fit model, và mỗi block trong train cũng không nhìn thấy tương lai của chính nó.

Mốc warmup 14 ngày được chọn như một thỏa hiệp giữa độ ổn định của recovery model và lượng dữ liệu còn lại để recover. Vì dữ liệu có mùa vụ theo giờ và theo tuần, 14 ngày tương ứng hai chu kỳ tuần đầy đủ, giúp mô hình nhìn thấy ít nhất hai lần lặp của các pattern theo thứ trong tuần và cuối tuần. Khoảng này cũng đủ để các đặc trưng lag/rolling ngắn hạn như lag 24 giờ, lag 168 giờ, rolling 24 giờ và rolling 168 giờ bắt đầu có ý nghĩa hơn trước khi fit recovery model đầu tiên. Nếu warmup quá ngắn, model recovery đầu tiên dễ học từ lịch sử quá ít và impute stockout thiếu ổn định; nếu quá dài, nhiều giờ stockout đầu kỳ bị giữ nguyên observed sales, làm giảm lợi ích của latent demand recovery. Do đó, 14 ngày là lựa chọn thực dụng cho đề án: đủ bao phủ seasonality tuần nhưng không làm mất quá nhiều train period.

Các bước cụ thể như sau:

1. **Warmup period:** 14 ngày đầu được giữ nguyên observed sales vì chưa đủ lịch sử để train recovery model ổn định.
2. **Chia train period thành block tuần:** sau warmup, train period được chia thành các block 7 ngày liên tiếp.
3. **Train recovery cho từng block:** với mỗi block, LightGBM recovery model chỉ được train trên các dòng non-stockout nằm trước thời điểm bắt đầu block.
4. **Recover block hiện tại:** model vừa train được dùng để ước lượng $imputed_demand$ cho block hiện tại; nếu dòng đó stockout, recovered demand bằng observed sales cộng phần lost demand đã calibration và cap.
5. **Validation/Test:** sau khi kết thúc train period, một final recovery model được train trên toàn bộ non-stockout rows của train period và dùng để recover validation/test.

Cách làm này tránh cả hai dạng leakage: không dùng validation/test để fit recovery model, và cũng không dùng các ngày phía sau trong train period để recover các ngày phía trước.

Table 8: Tóm tắt khôi phục latent demand

Metric	Value
Observed sales	482697.09375
Recovered latent demand	534270.1875
Recovered lost demand	51572.875
Recovered lift over observed	0.10684314370155334
Stockout row rate	0.24652109375
Recovery method	expanding-window weekly recovery
Imputation calibration factor	1.1297638401922185
Lost demand cap quantile	q90 of calibrated positive lost demand
Lost demand cap value	0.06627678871154785
Warmup days kept observed	14
Recovery block days	7
Recovery blocks	9
Final recovery train rows	400000
Recovery train source	past non-stockout rows only for train blocks; train-period non-stockout rows
Final recovery train end	2024-06-10 23:00:00
Validation start	2024-06-11 00:00:00
Test start	2024-06-18 00:00:00

Table 9: Các block expanding-window dùng trong latent demand recovery

Block start	Block end	Training end	Training rows	Predicted rows
2024-04-11	2024-04-18	2024-04-10 23:00:00	400000	840000
2024-04-18	2024-04-25	2024-04-17 23:00:00	400000	840000
2024-04-25	2024-05-02	2024-04-24 23:00:00	400000	840000
2024-05-02	2024-05-09	2024-05-01 23:00:00	400000	840000
2024-05-09	2024-05-16	2024-05-08 23:00:00	400000	840000
2024-05-16	2024-05-23	2024-05-15 23:00:00	400000	840000
2024-05-23	2024-05-30	2024-05-22 23:00:00	400000	840000
2024-05-30	2024-06-06	2024-05-29 23:00:00	400000	840000
2024-06-06	2024-06-11	2024-06-05 23:00:00	400000	600000




Figure 16: Observed sales và recovered latent demand theo thời gian.

7.2 Kiểm tra chất lượng imputation

Vì recovered demand là biến được ước lượng, báo cáo không xem imputation là ground truth tuyệt đối. Ta kiểm tra chất lượng impute theo ba hướng. Thứ nhất, đo tổng mức uplift để xem recovered demand có làm tổng sales tăng quá mức hay không. Thứ hai, dùng pseudo-stockout validation: lấy các dòng non-stockout trong validation period, giả sử chúng cần impute, rồi so sánh prediction của recovery model với observed sales thật. Thứ ba, kiểm tra sensitivity khi cap phần recovered lost demand ở các phân vị khác nhau.

Table 10: Tổng mức uplift do latent-demand imputation

Metric	Value
Observed sales	482,697
Recovered demand	534,270
Recovered lost demand	51,573
Recovered lift over observed	0.1068
Raw calibrated lost demand before cap	65,368
Cap retained share of raw lost demand	0.7890
Stockout row share	0.2465
Recovered lost demand from stockout rows	51,573
Mean stockout uplift per stockout row	0.0182

Table 11: Pseudo-stockout validation trên non-stockout rows

Metric	Value
Validation rows	300000
Pseudo-stockout source	non-stockout rows from validation period
RMSE	0.10030610859394073
MAE	0.05774029344320297
WAPE	1.0391554832458496
sMAPE	1.6277295807119518
Mean prediction / actual ratio	1.1315665245056152
Mean error actual-minus-imputed	-0.007310444954782724

Do dữ liệu hourly rất thưa và nhiều giá trị nhỏ/zero, row-level WAPE của pseudo-stockout validation có thể nhìn xấu hơn thực tế vận hành. Vì vậy, báo cáo bổ sung kiểm tra ở cấp aggregate, gồm hourly aggregate, daily aggregate và series-daily aggregate.

Table 12: Pseudo-stockout validation ở các cấp aggregate

Validation level	RMSE	MAE	WAPE	sMAPE	Prediction / actual ratio	N
Hourly aggregate	42.5877	21.9068	0.2208	0.2237	1.1316	168
Daily aggregate	450.9920	416.6911	0.1750	0.1677	1.1316	7
Series daily aggregate	0.3245	0.2155	0.4384	0.6309	1.1316	33907

Kết quả pseudo-stockout validation cho thấy recovery model có xu hướng dự đoán cao hơn observed sales trên các dòng non-stockout validation. Vì vậy, phần impute được xem là một proxy có kiểm soát chứ không phải nhãn thật. Trong pipeline chính, dự đoán raw được chia cho calibration factor 1.1297638401922185 và phần lost demand dương được cap ở giá trị 0.06627678871154785. Để tránh kết luận phụ thuộc quá mạnh vào impute, báo cáo thêm sensitivity theo mức cap lost demand.

Table 13: Sensitivity khi cap phần recovered lost demand

Scenario	Cap value	Recovered demand	Recovered lost demand	Recovered lift over observed	Share of original recovered lost demand
Cap lost-demand at q50	0.0151	505,963	23,266	0.0482	0.3559
Cap lost-demand at q75	0.0369	523,781	41,084	0.0851	0.6285
Cap lost-demand at q90	0.0663	534,270	51,573	0.1068	0.7890
Cap lost-demand at q100	2.7508	548,064	65,368	0.1354	1.0000

Ở mức toàn bộ dataset, recovered demand tăng khoảng 10.68% so với observed sales. Mức này không làm tổng demand tăng gấp nhiều lần, nhưng một số series có stockout rate rất cao có thể có lift lớn. Do đó, các series uplift cao được kiểm tra riêng để phát hiện trường hợp forecast phụ thuộc quá mạnh vào imputation.




Figure 17: Observed sales, recovered demand và phần lost demand recovered theo ngày.




Figure 18: Phân phối recovered lift ở cấp series.




Figure 19: Top series có recovered lift cao nhất.

Table 14: Top series phụ thuộc nhiều nhất vào imputation

series_id	observed_sales	recovered_demand	recovered_lost_demand	stockout_rate	Recovered lift over observed	Recovered share from imputation
0_554_90	39.3000	72.3776	33.0776	0.7339	0.8417	0.4570
0_597_41	39.8500	71.9541	32.1041	0.6150	0.8056	0.4462
3_724_188	45.3000	76.9671	31.6671	0.7248	0.6991	0.4114
4_356_90	39.0500	66.2217	27.1717	0.6029	0.6958	0.4103
11_533_129	43.7000	72.7158	29.0158	0.7161	0.6640	0.3990
6_493_129	44.2000	73.4980	29.2980	0.7357	0.6629	0.3986
0_173_90	55.3000	91.7408	36.4408	0.6536	0.6590	0.3972
5_6_757	44.5000	72.8119	28.3119	0.7448	0.6362	0.3888
12_228_129	45.7000	74.0857	28.3857	0.6667	0.6211	0.3831
3_835_333	46.7000	74.9063	28.2063	0.6944	0.6040	0.3766

Table 15: So sánh forecast trên observed sales và recovered demand

Model	Training target	Evaluation target	RMSE	MAE	WAPE	sMAPE	WPE	N
Recovered naive x7	baseline_no_training	Recovered latent demand proxy	4.3949	2.8080	0.3149	0.3870	-0.0198	70000
Recovered seasonal naive 7-day	baseline_no_training	Recovered latent demand proxy	2.9113	1.7704	0.1985	0.2269	-0.0614	70000
Recovered rolling mean 14-day	baseline_no_training	Recovered latent demand proxy	3.1099	1.8367	0.2060	0.2268	-0.0807	70000
Observed-sales forecasting	target_next7_observed_daily	Recovered latent demand proxy	3.6749	2.1780	0.2442	0.2755	-0.1788	70000
Observed-sales forecasting	target_next7_observed_daily	Observed sales	3.2644	1.7730	0.2206	0.2412	-0.0887	70000
Recovered-demand forecasting	target_next7_recovered_daily	Recovered latent demand proxy	3.6160	1.8082	0.2028	0.2135	-0.0800	70000
Recovered-demand forecasting	target_next7_recovered_daily	Observed sales	3.4820	1.7713	0.2204	0.2459	0.0209	70000
Recovered seasonal-ML hybrid	seasonal_naive_plus_recovered_lightgbm_alpha_0.60	Recovered latent demand proxy	3.2106	1.7545	0.1967	0.2127	-0.0726	70000




Figure 20: So sánh bias WPE khi đánh giá trên recovered latent demand proxy.




Figure 21: Dự báo tổng nhu cầu 7 ngày theo hướng two-stage.

8 Kết quả mô hình two-stage

Sau khi khôi phục latent demand, phần dự báo chính của đồ án không còn xem observed sales là target cuối cùng. Target chính là `target_next7_recovered_daily`, tức tổng nhu cầu 7 ngày tiếp theo sau khi đã hiệu chỉnh các giờ stockout. Để chứng minh lợi ích của two-stage, ta so sánh hai mô hình LightGBM có cùng dạng global model:

1. **Observed-sales forecasting:** train trên doanh số quan sát được, sau đó đánh giá lại trên recovered latent demand proxy.
2. **Recovered-demand forecasting:** train trực tiếp trên recovered demand và đánh giá trên recovered latent demand proxy.

Ngoài ra, báo cáo thêm các baseline daily không cần train như naive, seasonal naive 7 ngày và rolling mean 14 ngày. Seasonal naive 7 ngày là baseline rất mạnh vì phổ tần số và ACF đều cho thấy seasonality theo tuần. Mô hình cuối cùng được dùng để kết luận là **Recovered seasonal-ML hybrid**: blend giữa seasonal naive 7 ngày và Recovered-demand LightGBM, với trọng số được chọn trên validation set. Cách này giữ được nền mùa vụ mạnh của seasonal naive, đồng thời cho phép LightGBM hiệu chỉnh theo stockout, lag, rolling và calendar features.

Table 16: Kết quả chính của mô hình two-stage

Model	Training target	Evaluation target	RMSE	MAE	WAPE	sMAPE	WPE	N
Recovered naive x7	baseline_no_training	Recovered latent demand proxy	4.3949	2.8080	0.3149	0.3870	-0.0198	70000
Recovered seasonal naive 7-day	baseline_no_training	Recovered latent demand proxy	2.9113	1.7704	0.1985	0.2269	-0.0614	70000
Recovered rolling mean 14-day	baseline_no_training	Recovered latent demand proxy	3.1099	1.8367	0.2060	0.2268	-0.0807	70000
Observed-sales forecasting	target_next7_observed_daily	Recovered latent demand proxy	3.6749	2.1780	0.2442	0.2755	-0.1788	70000
Observed-sales forecasting	target_next7_observed_daily	Observed sales	3.2644	1.7730	0.2206	0.2412	-0.0887	70000
Recovered-demand forecasting	target_next7_recovered_daily	Recovered latent demand proxy	3.6160	1.8082	0.2028	0.2135	-0.0800	70000
Recovered-demand forecasting	target_next7_recovered_daily	Observed sales	3.4820	1.7713	0.2204	0.2459	0.0209	70000
Recovered seasonal-ML hybrid	seasonal_naive_plus_recovered_lightgbm_alpha_0.60	Recovered latent demand proxy	3.2106	1.7545	0.1967	0.2127	-0.0726	70000

Kết quả cho thấy train trên recovered demand làm giảm sai số khi đánh giá trên recovered latent demand proxy, đồng thời làm bias âm nhỏ hơn. Điều này quan trọng vì mô hình train trên observed sales có xu hướng under-forecast nhu cầu trong các giai đoạn từng bị stockout. Baseline seasonal naive 7 ngày cũng rất cạnh tranh, cho thấy tính mùa vụ tuần là pattern chính của dữ liệu. Hybrid seasonal-ML đạt WAPE 0.1967, là kết quả tốt nhất trong bảng, nên được dùng làm mô hình kết luận cuối.

Table 17: Chọn trọng số hybrid trên validation set

LightGBM weight	Seasonal naive weight	Validation WAPE
0.6000	0.4000	0.1901
0.5500	0.4500	0.1901
0.6500	0.3500	0.1902
0.5000	0.5000	0.1903
0.7000	0.3000	0.1903
0.4500	0.5500	0.1906
0.7500	0.2500	0.1906
0.4000	0.6000	0.1909




Figure 22: Bias WPE của mô hình observed-sales và recovered-demand khi đánh giá trên recovered latent demand proxy.




Figure 23: Dự báo tổng nhu cầu 7 ngày theo hướng two-stage.

8.1 Benchmark observed-sales hourly

Các kết quả $h=1$ và $h=24$ trên observed sales vẫn được giữ như benchmark phụ để cho thấy pipeline feature engineering và LightGBM hourly hoạt động hợp lý. Tuy nhiên, chúng không còn là kết quả chính vì observed sales bị kiểm duyệt trong các giờ stockout.

Table 18: Benchmark phụ trên observed sales cho horizon $h=1$

Model	RMSE	MAE	WAPE	sMAPE	N
LightGBM	0.0957	0.0513	1.0483	1.7028	1680000
Ridge	0.1019	0.0546	1.1141	1.7237	1680000
SeasonalNaive168	0.1323	0.0588	1.2007	0.5970	1680000
SeasonalNaive24	0.1367	0.0601	1.2260	0.5991	1680000
Naive	0.1414	0.0609	1.2441	0.5973	1680000

Table 19: Benchmark phụ trên observed sales cho horizon $h=24$

Model	RMSE	MAE	WAPE	sMAPE	N
LightGBM	0.0986	0.0525	1.0695	1.7195	1680000
Ridge	0.1025	0.0573	1.1663	1.7113	1680000
SeasonalNaive168	0.1314	0.0582	1.1837	0.5913	1680000
Naive	0.1350	0.0594	1.2094	0.5943	1680000
SeasonalNaive24	0.1350	0.0594	1.2094	0.5943	1680000

9 Diagnostics và khoảng dự báo two-stage

Diagnostics chính được thực hiện trên mô hình **Recovered seasonal-ML hybrid**, với residual được tính theo recovered latent demand proxy. Cách đánh giá này nhất quán với mục tiêu của two-stage: sau khi hiệu chỉnh latent demand, mô hình phải dự báo nhu cầu đã khử kiểm duyệt, không chỉ dự báo observed sales. Bảng dưới đây vẫn hiển thị cả baseline, observed-sales, recovered-demand và hybrid để so sánh trực tiếp, nhưng diễn giải chính tập trung vào mô hình có WAPE thấp nhất trên recovered latent demand proxy.

Table 20: Diagnostics của mô hình two-stage trên recovered latent demand proxy

Model	Evaluation target	RMSE	MAE	WAPE	sMAPE	WPE	Residual mean	Residual std	Ljung-Box p-value	Jarque-Bera p-value	N
Recovered naive x7	Recovered latent demand proxy	4.3949	2.8080	0.3149	0.3870	-0.0198	0.1770	4.3913	0.1790	0.0000	70000
Recovered seasonal naive 7-day	Recovered latent demand proxy	2.9113	1.7704	0.1985	0.2269	-0.0614	0.5475	2.8594	0.0131	0.0000	70000
Recovered rolling mean 14-day	Recovered latent demand proxy	3.1099	1.8367	0.2060	0.2268	-0.0807	0.7194	3.0255	0.0001	0.0000	70000
Observed-sales forecasting	Recovered latent demand proxy	3.6749	2.1780	0.2442	0.2755	-0.1788	1.5943	3.3111	0.0127	0.0000	70000
Recovered-demand forecasting	Recovered latent demand proxy	3.6160	1.8082	0.2028	0.2135	-0.0800	0.7134	3.5450	0.0665	0.0000	70000
Recovered seasonal-ML hybrid	Recovered latent demand proxy	3.2106	1.7545	0.1967	0.2127	-0.0726	0.6470	3.1448	0.0311	0.0000	70000




Figure 24: Phân phối residual của recovered-demand forecasting trên recovered latent demand proxy.




Figure 25: Residual ACF của recovered-demand forecasting theo daily aggregate.




Figure 26: So sánh WAPE diagnostics của hai hướng train khi đánh giá trên recovered latent demand proxy.

Vì target của bài toán là tổng nhu cầu 7 ngày tiếp theo, các nhãn dự báo theo từng ngày bị overlap mạnh: forecast tại ngày t và ngày $t+1$ chia sẻ 6/7 ngày trong target. Do đó, residual theo daily rolling evaluation có thể tự tương quan một phần do thiết kế target, không chỉ do mô hình học thiếu pattern. Để kiểm tra độc lập residual công bằng hơn, báo cáo thêm diagnostics trên các mốc non-overlapping cách nhau 7 ngày. Với Recovered seasonal-ML hybrid, diagnostics chính có Ljung–Box p-value 0.0311, tức vẫn còn tự tương quan nhẹ ở mức 5% nếu đánh giá trên rolling target bị overlap. Diagnostics non-overlapping có Ljung–Box p-value 0.1573, nên không bác bỏ tự tương quan ở mức 5% trong kiểm tra phụ. Tuy nhiên, do test set chỉ có 14 ngày nên non-overlapping aggregate chỉ có hai mốc thời gian; kết quả này được dùng như kiểm tra phụ, không phải bằng chứng tuyệt đối.

Table 21: Diagnostics trên non-overlapping 7-day targets

Model	Evaluation mode	Evaluation dates	RMSE	MAE	WAPE	WPE	Ljung-Box p-value	N	Aggregate residual points
Recovered naive x7	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	4.6707	2.9483	0.3389	0.0080	0.1573	10000	2
Recovered seasonal naive 7-day	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	2.8150	1.7140	0.1970	-0.0662	0.1573	10000	2
Recovered rolling mean 14-day	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	3.0150	1.7821	0.2049	-0.0738	0.1573	10000	2
Observed-sales forecasting	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	3.5320	2.1044	0.2419	-0.1753	0.1573	10000	2
Recovered-demand forecasting	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	3.3906	1.7544	0.2017	-0.0716	0.1573	10000	2
Recovered seasonal-ML hybrid	Non-overlapping 7-day targets	2024-06-11; 2024-06-18	3.0564	1.7001	0.1954	-0.0695	0.1573	10000	2

Khoảng dự báo được xây dựng từ phân vị residual trên validation set của mô hình two-stage. Cách này không giả định residual phân phối chuẩn tuyệt đối, phù hợp hơn với dữ liệu bán lẻ thưa và có nhiều giá trị zero.




Figure 27: Khoảng dự báo 80\{\}% và 95\{\}% của mô hình two-stage trên recovered latent demand.

10 Diễn giải đặc trưng của mô hình two-stage

Với hướng two-stage, feature importance chính được lấy từ mô hình **Recovered-demand forecasting** thay vì LightGBM hourly observed-sales. Các đặc trưng quan trọng nhất chủ yếu là lag và rolling statistics của recovered demand, vì chúng mô tả mức nền nhu cầu sau khi đã hiệu chỉnh stockout. Biến `stockout_rate` vẫn được giữ trong mô hình forecasting để mô hình biết mức độ kiểm duyệt gần đây của chuỗi.

Table 22: Top đặc trưng quan trọng của recovered-demand forecasting

feature	importance
<code>stockout_rate</code>	986
<code>recovered_daily_lag_28</code>	969
<code>recovered_daily_lag_1</code>	820
<code>recovered_daily_lag_14</code>	814
<code>recovered_daily_lag_7</code>	794
<code>recovered_daily_lag_2</code>	699
<code>recovered_daily_roll_mean_28</code>	671
<code>recovered_daily_roll_sum_28</code>	585
<code>day_of_week</code>	518
<code>recovered_daily_roll_mean_7</code>	490
<code>month</code>	410
<code>recovered_daily_roll_mean_14</code>	392
<code>recovered_daily_roll_sum_14</code>	329
<code>recovered_daily_roll_sum_7</code>	289
<code>is_weekend</code>	23




Figure 28: Top 20 feature importance của mô hình recovered-demand forecasting.

11 Phân tích bổ sung trên benchmark observed-sales

Các phân tích trong mục này được giữ như sanity check cho pipeline feature engineering ban đầu. Chúng không phải kết quả chính của đồ án, vì target của chúng vẫn là observed sales. Tuy nhiên, chúng giúp giải thích vì sao các nhóm đặc trưng thời gian, promotion, weather và stockout-aware vẫn hữu ích trước khi chuyển sang mô hình two-stage.

11.1 Ablation study

Ablation study kiểm tra giá trị gia tăng của promotion, weather và stockout features trên benchmark LightGBM observed-sales.

Table 23: Kết quả ablation LightGBM trên observed-sales benchmark

Horizon	Feature set	RMSE	MAE	WAPE	sMAPE	Train rows used
1	Lag + Calendar + Promotion + Weather + Stockout	0.0972	0.0525	1.0710	1.7026	500000
1	Lag + Calendar + Promotion	0.0983	0.0544	1.1109	1.7125	500000
1	Lag + Calendar + Promotion + Weather	0.0991	0.0546	1.1143	1.7122	500000
1	Lag + Calendar	0.0987	0.0546	1.1153	1.7118	500000




Figure 29: Ablation theo WAPE cho h=1.

11.2 Phân tích stockout và nhu cầu bị kiểm duyệt

Khi hết hàng, doanh số quan sát được có thể thấp hơn nhu cầu thực. Phân tích lost-sales proxy ban đầu dùng rolling mean 168 giờ để minh họa cơ chế censoring; pipeline chính sau đó thay proxy thô này bằng expanding-window latent demand recovery.

Table 24: Tóm tắt stockout-censoring và lost-sales proxy

Metric	Value
Observed sales	482,696
Lost sales proxy during stockout	107,735
Adjusted demand proxy	590,432
Stockout row rate	0.2465
Lost sales proxy / observed sales	0.2232




Figure 30: Doanh số quan sát và lost-sales proxy theo giờ.

Table 25: Đánh giá riêng stockout và non-stockout periods

Horizon	Model	Segment	RMSE	MAE	WAPE	sMAPE	N
1	LightGBM	non_stockout_period	0.1065	0.0609	0.9779	1.6196	1293347
1	LightGBM	overall	0.0957	0.0513	1.0483	1.7028	1680000
1	LightGBM	stockout_period	0.0427	0.0192	4.3970	1.9813	386653
1	Naive	non_stockout_period	0.1513	0.0707	1.1348	0.6882	1293347
1	Naive	overall	0.1414	0.0609	1.2441	0.5973	1680000
1	Naive	stockout_period	0.1014	0.0282	6.4489	0.2934	386653
1	Ridge	non_stockout_period	0.1116	0.0616	0.9890	1.6465	1293347
1	Ridge	overall	0.1019	0.0546	1.1141	1.7237	1680000
1	Ridge	stockout_period	0.0590	0.0310	7.0744	1.9821	386653
1	SeasonalNaive168	non_stockout_period	0.1410	0.0669	1.0731	0.6649	1293347
1	SeasonalNaive168	overall	0.1323	0.0588	1.2007	0.5970	1680000
1	SeasonalNaive168	stockout_period	0.0977	0.0319	7.2799	0.3697	386653
1	SeasonalNaive24	non_stockout_period	0.1444	0.0678	1.0881	0.6660	1293347
1	SeasonalNaive24	overall	0.1367	0.0601	1.2260	0.5991	1680000
1	SeasonalNaive24	stockout_period	0.1073	0.0341	7.7945	0.3754	386653
24	LightGBM	non_stockout_period	0.1069	0.0587	0.9386	1.6422	1291783
24	LightGBM	overall	0.0986	0.0525	1.0695	1.7195	1680000
24	LightGBM	stockout_period	0.0639	0.0319	7.2645	1.9765	388217
24	Naive	non_stockout_period	0.1448	0.0682	1.0906	0.6682	1291783
24	Naive	overall	0.1350	0.0594	1.2094	0.5943	1680000
24	Naive	stockout_period	0.0957	0.0301	6.8366	0.3484	388217
24	Ridge	non_stockout_period	0.1108	0.0630	1.0068	1.6325	1291783
24	Ridge	overall	0.1025	0.0573	1.1663	1.7113	1680000
24	Ridge	stockout_period	0.0682	0.0383	8.7163	1.9736	388217
24	SeasonalNaive168	non_stockout_period	0.1413	0.0670	1.0709	0.6664	1291783
24	SeasonalNaive168	overall	0.1314	0.0582	1.1837	0.5913	1680000
24	SeasonalNaive168	stockout_period	0.0909	0.0287	6.5264	0.3416	388217
24	SeasonalNaive24	non_stockout_period	0.1448	0.0682	1.0906	0.6682	1291783
24	SeasonalNaive24	overall	0.1350	0.0594	1.2094	0.5943	1680000
24	SeasonalNaive24	stockout_period	0.0957	0.0301	6.8366	0.3484	388217

11.3 Kiểm tra độ ổn định và mô hình cổ điển

Rolling-window evaluation cho thấy hiệu năng LightGBM observed-sales tương đối ổn định giữa hai tuần test. Ngoài ra, SARIMAX trên chuỗi tổng hợp được dùng như đối chứng time-series cổ điển. Kết quả cho thấy SARIMAX aggregate không tự động thắng seasonal naive 168h, nhấn mạnh sức mạnh của mùa vụ tuần và sự cần thiết của benchmark.

Table 26: Rolling-window evaluation trên test set

Horizon	Model	Window start	Window end	RMSE	MAE	WAPE	sMAPE	N
1	LightGBM	2024-06-18	2024-06-24 23:00:00	0.0956	0.0512	1.0556	1.7063	840000
1	LightGBM	2024-06-25	2024-07-01 23:00:00	0.0958	0.0515	1.0410	1.6994	840000
1	SeasonalNaive168	2024-06-18	2024-06-24 23:00:00	0.1300	0.0577	1.1883	0.5922	840000
1	SeasonalNaive168	2024-06-25	2024-07-01 23:00:00	0.1346	0.0600	1.2129	0.6018	840000
24	LightGBM	2024-06-18	2024-06-24 23:00:00	0.0987	0.0525	1.0679	1.7224	840000
24	LightGBM	2024-06-25	2024-07-01 23:00:00	0.0985	0.0526	1.0710	1.7166	840000
24	SeasonalNaive168	2024-06-18	2024-06-24 23:00:00	0.1298	0.0574	1.1669	0.5877	840000
24	SeasonalNaive168	2024-06-25	2024-07-01 23:00:00	0.1330	0.0590	1.2006	0.5950	840000

Table 27: So sánh SARIMAX tổng hợp với seasonal naive

Model	RMSE	MAE	WAPE	sMAPE	AIC	BIC
AggregateSARIMAX	70.2814	32.7022	0.1335	0.1244	18,261	18,289
AggregateSeasonalNaive168	36.2745	21.7752	0.0889	0.1006		




Figure 31: Dự báo SARIMAX trên chuỗi tổng hợp observed-sales.

12 Kết luận và hạn chế

Đề án cuối cùng được tiếp cận theo hướng two-stage: trước hết khôi phục latent demand trong các giờ stockout bằng expanding-window recovery, sau đó forecast trên daily recovered demand. Khi đánh giá trên recovered latent demand proxy, LightGBM train trên recovered demand đạt WAPE 0.2028, tốt hơn mô hình train trên observed sales với WAPE 0.2442. Seasonal naive 7 ngày là baseline rất mạnh; vì vậy mô hình kết luận cuối dùng hybrid seasonal-ML chọn trọng số trên validation. Hybrid đạt WAPE 0.1967 và WPE -0.0726, là kết quả tốt nhất trong nhóm mô hình/baseline đã thử. Điều này cho thấy hướng two-stage có ích, nhưng cũng nhấn mạnh rằng seasonality tuần là thành phần nền không thể bỏ qua.

Hạn chế chính là recovered demand vẫn là proxy được ước lượng từ mô hình, không phải ground truth nhu cầu thật. Ngoài ra, diagnostics chính trên rolling 7-day target vẫn còn tự tương quan nhẹ vì các target liên tiếp overlap mạnh; kiểm tra non-overlapping không bác bỏ tự tương quan nhưng chỉ có ít điểm aggregate. Jarque–Bera vẫn bác bỏ phân phối chuẩn. Điều này phù hợp với bản chất dữ liệu bán lẻ thưa, nhiều zero và có spike do khuyến mãi/tồn kho. Hướng phát triển tiếp theo là thử các mô hình recovery chuyên biệt hơn như SAITS, TimesNet, DLinear hoặc ImputeFormer, đồng thời kiểm tra sensitivity của warmup length và block size.