

Dự báo nhu cầu bán lẻ có xét đến stockout trên
FreshRetailNet-50K

Abstract

Báo cáo này trình bày một pipeline stockout-aware demand forecasting cho FreshRetailNet-50K. Thay vì dự báo trực tiếp observed sales, đồ án recover latent demand trong các giờ stock-out, aggregate lên daily demand, rồi forecast tổng nhu cầu 7 ngày tiếp theo. Trọng tâm của báo cáo là tính đúng đắn theo thời gian, kiểm soát imputation, so sánh với benchmark và diễn giải business.

Contents

0.1	Giới thiệu và động lực kinh doanh	1
0.1.1	Câu hỏi nghiên cứu	1
0.1.2	Đóng góp chính của đồ án	1
0.1.3	Phạm vi và điều không claim	2
0.1.4	Kết quả chính ở mức tổng quan	2
0.2	Dữ liệu và tiền xử lý	2
0.2.1	Nguồn dữ liệu	2
0.2.2	Tạo định danh chuỗi	2
0.2.3	Bung dữ liệu daily thành hourly	3
0.2.4	Lấy sample theo series	3
0.2.5	Split theo thời gian	3
0.3	Phân tích khám phá dữ liệu	4
0.3.1	Aggregate sales và stockout	4
0.3.2	Phân phối sales	5
0.3.3	Seasonality theo giờ và theo tuần	6
0.3.4	Chuỗi đại diện	7
0.4	Kiểm tra time-series: stationarity, ACF/PACF và spectrum	8
0.4.1	Stationarity testing	8
0.4.2	ACF/PACF	9
0.4.3	Spectrum analysis	11
0.5	Phương pháp	12
0.5.1	Vì sao không forecast observed sales trực tiếp?	12
0.5.2	Two-stage framework	13
0.5.3	Expanding-window recovery	14
0.5.4	Calibration và cap	15
0.5.5	Daily forecasting target	15
0.5.6	Modeling choice	15
0.5.7	Baselines và hybrid	15
0.6	Latent demand recovery và kiểm soát imputation	15
0.6.1	Kết quả recovery tổng quan	15
0.6.2	Uplift do imputation	16
0.6.3	Pseudo-stockout validation	17

0.6.4	Sensitivity theo cap	18
0.7	Forecasting results	19
0.7.1	So sánh không impute và có impute	19
0.7.2	Seasonal naive là baseline mạnh	20
0.7.3	Hybrid seasonal-ML	21
0.7.4	Business interpretation	21
0.7.5	Feature importance	21
0.8	Diagnostics và forecast uncertainty	23
0.8.1	Residual diagnostics	23
0.8.2	Non-overlap diagnostics	24
0.8.3	Prediction intervals	24
0.9	Business insights	25
0.9.1	Insight 1: Stockout làm sai lệch tín hiệu demand	25
0.9.2	Insight 2: Latent demand recovery cho biết mức demand bị bỏ lỡ . . .	25
0.9.3	Insight 3: Weekly seasonality là baseline nghiệp vụ mạnh	25
0.9.4	Insight 4: Model cuối nên hỗ trợ replenishment	25
0.9.5	Khuyến nghị triển khai	26
0.10	Kết luận, hạn chế và hướng phát triển	26
0.10.1	Kết luận	26
0.10.2	Hạn chế	26
0.10.3	Hướng phát triển	26
.1	Phụ lục A: Bảng hỗ trợ trực tiếp	27
.2	Phụ lục B: Reproducibility	28

List of Figures

1	Tổng observed sales theo giờ.	4
2	Tỷ lệ stockout theo giờ.	5
3	Phân phối sale amount hourly.	5
4	Phân phối log1p sale amount hourly.	6
5	Sales trung bình theo giờ trong ngày.	6
6	Sales trung bình theo thứ trong tuần.	7
7	Chuỗi đại diện high-volume.	7
8	Chuỗi đại diện intermittent.	8
9	Chuỗi đại diện stockout-heavy.	8
10	ACF của aggregate hourly sales.	9

11	PACF của aggregate hourly sales.	10
12	ACF của chuỗi high-volume.	10
13	PACF của chuỗi high-volume.	10
14	Spectrum của hourly aggregate observed sales.	11
15	Spectrum của daily recovered demand.	12
16	Quy trình tổng quát two-stage.	13
17	Chi tiết expanding-window recovery.	14
18	Observed sales và recovered demand theo thời gian.	16
19	Observed sales, recovered demand và recovered lost demand theo ngày.	17
20	Phân phối recovered lift ở cấp series.	19
21	Top series có lift cao nhất.	19
22	Forecast tổng nhu cầu 7 ngày.	20
23	WAPE của các mô hình/baseline trên recovered latent demand proxy.	20
24	Top 20 feature importance.	22
25	Phân phối residual của mô hình chính.	23
26	Residual ACF của mô hình chính.	24
27	Khoảng dự báo 80\{\}% và 95\{\}% cho mô hình chính.	25

List of Tables

1	Tóm tắt contribution của đề án	1
2	Tóm tắt chất lượng dữ liệu	3
3	Split hourly theo thời gian	4
4	Split daily forecasting theo forecast origin	4
5	Ba chuỗi đại diện	7
6	Kết quả ADF/KPSS	9
7	Các peak spectrum hourly	11
8	Các peak spectrum daily	12
9	Tóm tắt latent demand recovery	16
10	Tổng mức uplift do imputation	17
11	Pseudo-stockout validation ở cấp row hourly	18
12	Pseudo-stockout validation ở các cấp aggregate	18
13	Sensitivity theo mức cap lost demand	18
14	So sánh mô hình/baseline trên recovered latent demand proxy	20
15	Chọn trọng số hybrid trên validation	21
16	Feature importance của recovered-demand LightGBM	22

17	Diagnostics trên recovered latent demand proxy	23
18	Diagnostics trên non-overlapping 7-day targets	24
19	Các block expanding-window dùng cho recovery	27
20	Top series theo recovered lift	27
21	Diagnostics phụ trên non-overlapping target	27

0.1 Giới thiệu và động lực kinh doanh

Bài toán trong đề án này không chỉ là dự báo doanh số bán được trong tương lai. Trong bán lẻ, doanh số quan sát được có thể bị giới hạn bởi tồn kho: khi một sản phẩm hết hàng, số lượng bán được thấp không phản ánh đầy đủ nhu cầu thật. Nếu doanh nghiệp dùng trực tiếp doanh số quan sát được để dự báo, hệ thống có thể học nhầm rằng nhu cầu thấp, từ đó nhập hàng ít hơn, tiếp tục gây stockout trong các kỳ sau. Đây là vòng lặp vận hành quan trọng:

stockout -> observed sales thấp -> forecast thấp -> nhập ít -> tiếp tục stockout

Vì vậy, câu hỏi nghiên cứu của đề án được đặt lại theo hướng gần với nghiệp vụ hơn: làm thế nào để dự báo nhu cầu bán lẻ khi dữ liệu doanh số bị kiểm duyệt bởi trạng thái hết hàng? Thay vì chỉ dự báo *observed sales*, báo cáo này xây dựng pipeline dự báo *recovered demand*, tức nhu cầu được hiệu chỉnh sau khi xét đến stockout.

0.1.1 Câu hỏi nghiên cứu

Báo cáo tập trung vào bốn câu hỏi chính. Thứ nhất, dữ liệu FreshRetailNet-50K có các pattern thời gian nào quan trọng cho dự báo, đặc biệt là seasonality theo giờ, theo ngày và theo tuần? Thứ hai, stockout làm observed sales bị kiểm duyệt ở mức độ nào và có cần latent demand recovery hay không? Thứ ba, recovery demand có làm tổng nhu cầu tăng quá mức hay không, và làm sao kiểm soát rủi ro imputation? Thứ tư, sau khi recover demand, mô hình forecasting nào phù hợp nhất cho bài toán daily next-7-day demand?

0.1.2 Đóng góp chính của đề án

Đóng góp của đề án được hiểu theo nghĩa thực nghiệm và ứng dụng, không phải đề xuất một thuật toán deep learning hoàn toàn mới. Điểm mới nằm ở cách framing bài toán, cách xử lý stockout và cách biến kết quả forecast thành insight vận hành.

Table 1: Tóm tắt contribution của đề án

Nhóm đóng góp	Nội dung thực hiện	Ý nghĩa
Problem framing	Chuyển từ forecast observed sales sang forecast recovered demand	Gần hơn với quyết định replenishment
Data treatment	Recover latent demand ở cấp hourly rồi aggregate lên daily	Giữ đúng nơi stockout xuất hiện nhưng trả forecast ở cấp vận hành
Leakage control	Expanding-window recovery theo block tuần	Không dùng ngày tương lai để recover quá khứ
Imputation control	Calibration, cap q90, pseudo-stockout validation, sensitivity	Tránh để imputation làm phình tổng demand quá mức
Modeling insight	So sánh observed-sales, recovered-demand, seasonal naive và hybrid	Chứng minh seasonality tuần là baseline rất mạnh
Business insight	Đo mức demand bị che bởi stockout và tác động lên forecast	Hỗ trợ nhận diện SKU/store có rủi ro thiếu hàng

Nói ngắn gọn, contribution chính không phải là “dùng LightGBM” hay “vẽ thêm nhiều biểu đồ”. Contribution chính là xây dựng một quy trình forecast có xét cơ chế stockout-censoring:

observed sales bị kiểm duyệt, demand được recover có kiểm soát, sau đó forecast được đánh giá trên demand proxy phù hợp hơn cho vận hành.

0.1.3 Phạm vi và điều không claim

Đồ án không claim rằng recovered demand là ground truth tuyệt đối. Đây là proxy được ước lượng từ dữ liệu non-stockout và được kiểm soát bằng các kiểm tra aggregate/sensitivity. Đồ án cũng không claim đánh bại mọi mô hình deep learning hiện đại. Mục tiêu là một pipeline chặt chẽ, tái lập được, có benchmark rõ ràng và diễn giải được về mặt business.

0.1.4 Kết quả chính ở mức tổng quan

Sample thí nghiệm dùng 0.1 theo cấp `series_id`, gồm 11640000 quan sát hourly và 5000 chuỗi, từ 2024-03-28 00:00:00 đến 2024-07-02 23:00:00. Tỷ lệ stockout row khoảng 24.65%. Sau recovery, recovered demand tăng khoảng 10.68% so với observed sales, cho thấy observed sales có khả năng đang understated demand do hết hàng.

Khi đánh giá trên recovered latent demand proxy, observed-sales LightGBM đạt WAPE 24.42%; recovered-demand LightGBM giảm xuống 20.28%. Seasonal naive 7-day đạt 19.85%, cho thấy seasonality tuần rất mạnh. Mô hình kết luận cuối là Recovered seasonal-ML hybrid, đạt WAPE 19.67%.

0.2 Dữ liệu và tiền xử lý

0.2.1 Nguồn dữ liệu

FreshRetailNet-50K là bộ dữ liệu bán lẻ nhiều chuỗi, trong đó mỗi chuỗi tương ứng với một tổ hợp cửa hàng–sản phẩm–thành phố. Dữ liệu gốc gồm các file `train.parquet` và `eval.parquet`. Điểm đặc biệt của bộ dữ liệu là ngoài sales, dữ liệu còn chứa trạng thái tồn kho theo giờ thông qua `hours_stock_status`, giúp phân biệt giai đoạn bán thấp vì nhu cầu thấp và giai đoạn bán thấp vì hết hàng.

0.2.2 Tạo định danh chuỗi

Biến `series_id` được tạo từ `city_id`, `store_id` và `product_id`. Việc tạo định danh này giúp mọi phép lag, rolling và split được thực hiện đúng theo từng chuỗi, không trộn thông tin giữa các sản phẩm hoặc cửa hàng khác nhau.

0.2.3 Bung dữ liệu daily thành hourly

Dữ liệu sale theo ngày được bung thành hourly bằng `hours_sale`. Trạng thái stockout theo giờ được lấy từ `hours_stock_status`. Việc giữ cấp hourly là cần thiết vì stockout xảy ra theo giờ; nếu aggregate trực tiếp lên daily trước khi recover, ta có thể làm mất thông tin về thời điểm hết hàng trong ngày.

0.2.4 Lấy sample theo series

Đồ án không yêu cầu chạy full data. Vì vậy, sample 10% được lấy ở cấp `series_id`, giữ nguyên toàn bộ dòng thời gian của các chuỗi được chọn. Cách lấy sample này tốt hơn random row sampling vì không phá vỡ cấu trúc thời gian và không tạo chuỗi bị đứt đoạn.

Table 2: Tóm tắt chất lượng dữ liệu

Metric	Value
Sample fraction	0.1
Number of rows	11640000
Number of series	5000
Number of stores	866
Number of products	516
Number of cities	18
Start date	2024-03-28 00:00:00
End date	2024-07-02 23:00:00
Frequency	Hourly rows expanded from <code>hours_sale</code> and <code>hours_stock_status</code>
Missing dt count	0
Duplicate rows	0
Missing sale_amount	0
Stockout rate	0.24667061855670103
Average sale_amount	0.04194150120019913
Median sale_amount	0.0

0.2.5 Split theo thời gian

Tất cả các bước đánh giá đều dùng split theo thời gian, không dùng random split. Với dữ liệu hourly, validation gồm 7 ngày và test gồm 14 ngày cuối. Với bài toán daily next-7-day forecasting, báo cáo lưu thêm split theo forecast origin để làm rõ ngày dự báo và target window tương ứng.

Table 3: Split hourly theo thời gian

Split	Start date	End date	Rows	Series
Train	2024-03-28	2024-06-10 23:00:00	9000000	5000
Validation	2024-06-11	2024-06-17 23:00:00	840000	5000
Test	2024-06-18	2024-07-01 23:00:00	1680000	5000

Table 4: Split daily forecasting theo forecast origin

Split	Origin start	Origin end	Target window start	Target window end	Rows	Series
Train	2024-03-28	2024-06-03	2024-03-29	2024-06-10	340000	5000
Validation	2024-06-04	2024-06-10	2024-06-05	2024-06-17	35000	5000
Test	2024-06-11	2024-06-24	2024-06-12	2024-07-01	70000	5000

0.3 Phân tích khám phá dữ liệu

0.3.1 Aggregate sales và stockout

Hai hình đầu tiên cho thấy bức tranh tổng quát của dữ liệu: aggregate observed sales theo thời gian và stockout rate theo thời gian. Đây là hai đồ thị quan trọng nhất để motivate bài toán. Nếu chỉ nhìn aggregate sales, các giai đoạn giảm bán có thể bị hiểu là demand giảm. Nhưng khi đặt cạnh stockout rate, ta thấy cần phân biệt giữa demand thấp và availability thấp.




Figure 1: Tổng observed sales theo giờ.




Figure 2: Tỷ lệ stockout theo giờ.

0.3.2 Phân phối sales

Phân phối sale amount cho thấy dữ liệu bán lẻ rất thưa, nhiều giá trị nhỏ và zero, đồng thời có các spike lớn. Đây là lý do không dùng MAPE đơn thuần làm metric chính; WAPE, MAE và RMSE phù hợp hơn vì ổn định hơn khi dữ liệu có nhiều zero.




Figure 3: Phân phối sale amount hourly.




Figure 4: Phân phối log1p sale amount hourly.

0.3.3 Seasonality theo giờ và theo tuần

Seasonality là insight quan trọng nhất của dữ liệu. Sales thay đổi theo giờ trong ngày và theo thứ trong tuần. Điều này giải thích vì sao seasonal naive theo tuần là baseline rất mạnh ở phần kết quả. Trong bối cảnh bán lẻ, pattern tuần phản ánh hành vi mua sắm lặp lại của khách hàng, lịch hoạt động của cửa hàng và các chu kỳ khuyến mãi.




Figure 5: Sales trung bình theo giờ trong ngày.




Figure 6: Sales trung bình theo thứ trong tuần.

0.3.4 Chuỗi đại diện

Để không plot hàng nghìn chuỗi, báo cáo chọn ba chuỗi đại diện: high-volume, intermittent và stockout-heavy. Ba nhóm này minh họa ba kiểu khó khác nhau của forecasting: chuỗi lớn có pattern rõ, chuỗi thưa có nhiều zero, và chuỗi stockout-heavy có observed sales bị censor nặng.

Table 5: Ba chuỗi đại diện

series_id	type	total_sales	stockout_rate	n_obs
4_11_267	high_volume	1,896	0.6070	2328
3_793_550	intermittent	49.7000	0.1907	2328
5_6_757	stockout_heavy	48.4000	0.7371	2328




Figure 7: Chuỗi đại diện high-volume.




Figure 8: Chuỗi đại diện intermittent.




Figure 9: Chuỗi đại diện stockout-heavy.

0.4 Kiểm tra time-series: stationarity, ACF/PACF và spectrum

0.4.1 Stationarity testing

Theo yêu cầu môn học, báo cáo vẫn thực hiện ADF và KPSS trên aggregate series và các chuỗi đại diện. Tuy nhiên, với bài toán nhiều chuỗi bán lẻ, mục đích của stationarity test không phải để ép toàn bộ pipeline thành ARIMA cổ điển. Thay vào đó, ADF/KPSS giúp nhận diện mức độ trend/seasonality và củng cố quyết định dùng lag, rolling và seasonal baseline.

Table 6: Kết quả ADF/KPSS

Series	Transformation	ADF p-value	KPSS p-value	Conclusion	N
aggregate_hourly_sales	original	0.0000	0.0100	mixed evidence	2328
aggregate_hourly_sales	log1p	0.0000	0.0100	mixed evidence	2328
aggregate_hourly_sales	first_difference	0.0000	0.1000	stationary	2327
aggregate_hourly_sales	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
high_volume_series	original	0.3070	0.0100	non-stationary	2328
high_volume_series	log1p	0.4265	0.0100	non-stationary	2328
high_volume_series	first_difference	0.0000	0.1000	stationary	2327
high_volume_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
intermittent_series	original	0.0000	0.1000	stationary	2328
intermittent_series	log1p	0.0000	0.1000	stationary	2328
intermittent_series	first_difference	0.0000	0.1000	stationary	2327
intermittent_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304
stockout_heavy_series	original	0.0058	0.0100	mixed evidence	2328
stockout_heavy_series	log1p	0.0031	0.0100	mixed evidence	2328
stockout_heavy_series	first_difference	0.0000	0.1000	stationary	2327
stockout_heavy_series	seasonal_difference_lag_24	0.0000	0.1000	stationary	2304

0.4.2 ACF/PACF

ACF/PACF cho thấy autocorrelation và seasonal dependence ở các lag ngắn và lag theo ngày/tuần. Với dữ liệu hourly, lag 24 và 168 có ý nghĩa tự nhiên. Trong pipeline cuối, recovery được làm ở cấp hourly, còn forecasting được aggregate lên daily và dùng lag 7/14/28 ngày.




Figure 10: ACF của aggregate hourly sales.




Figure 11: PACF của aggregate hourly sales.




Figure 12: ACF của chuỗi high-volume.




Figure 13: PACF của chuỗi high-volume.

0.4.3 Spectrum analysis

Periodogram được dùng như một cách kiểm tra độc lập trong miền tần số. Hourly aggregate sales có peak mạnh quanh 24 giờ, còn daily recovered demand có peak gần 7 ngày. Điều này giải thích vì sao seasonal naive 7 ngày không phải baseline yếu mà là benchmark rất khó đánh bại.




Figure 14: Spectrum của hourly aggregate observed sales.

Table 7: Các peak spectrum hourly

Rank	Period	Frequency	Power	Period unit
1	24.0000	0.0417	0.6365	hours
2	8.0000	0.1250	0.1182	hours
3	12.0000	0.0833	0.0559	hours
4	6.0000	0.1667	0.0325	hours
5	164.5714	0.0061	0.0106	hours
6	28.0976	0.0356	0.0099	hours
7	12.9438	0.0773	0.0058	hours
8	20.9455	0.0477	0.0053	hours




Figure 15: Spectrum của daily recovered demand.

Table 8: Các peak spectrum daily

Rank	Period	Frequency	Power	Period unit
1	6.8462	0.1461	0.2108	days
2	3.5600	0.2809	0.0679	days
3	4.4500	0.2247	0.0232	days
4	2.3421	0.4270	0.0169	days
5	5.9333	0.1685	0.0169	days
6	5.2353	0.1910	0.0118	days
7	2.1190	0.4719	0.0100	days
8	9.8889	0.1011	0.0081	days

0.5 Phương pháp


0.5.1 Vì sao không forecast observed sales trực tiếp?

Observed sales là biến có thể bị censor bởi tồn kho. Trong giờ stockout, doanh số quan sát được là phần bán được trước khi hết hàng hoặc bằng không, không nhất thiết bằng demand thật. Nếu train model trực tiếp trên observed sales, mô hình có thể học rằng các chuỗi thường hết hàng có demand thấp. Điều này dẫn đến under-forecast và quyết định replenishment thiếu hàng.

0.5.2 Two-stage framework

Pipeline chính gồm hai stage. Stage 1 recover latent demand ở cấp hourly cho các giờ stockout. Stage 2 aggregate hourly recovered demand lên daily và forecast tổng nhu cầu 7 ngày tiếp theo. Cách này giữ thông tin stockout chi tiết ở nơi nó xuất hiện, nhưng trả forecast cuối ở cấp daily phù hợp hơn cho quyết định vận hành.

Quy trình stockout-aware latent demand recovery và forecasting




Nguyên tắc: chỉ dùng dữ liệu quá khứ để recover block hiện tại; validation/test không được dùng để fit recovery model.

Figure 16: Quy trình tổng quát two-stage.

0.5.3 Expanding-window recovery

Điểm dễ gây leakage nhất là latent demand recovery. Nếu dùng dữ liệu tương lai để impute quá khứ, forecast sau đó sẽ quá lạc quan. Vì vậy, trong train period, recovery được thực hiện theo block 7 ngày: mỗi block chỉ được recover bằng model học từ non-stockout rows nằm trước block đó. Validation/test được recover bằng final recovery model train trên non-stockout rows của train period.

Quy trình xử lý riêng cho expanding-window recovery



Mỗi block chỉ nhìn về quá khứ: không dùng ngày phía sau để recover ngày phía trước; validation/test không được dùng để fit recovery model.

Figure 17: Chi tiết expanding-window recovery.

0.5.4 Calibration và cap

Raw imputed demand có thể overpredict. Do đó, dự đoán raw được hiệu chỉnh bằng calibration factor học từ validation non-stockout rows. Sau đó lost demand dương được cap ở q90 để tránh một số giờ stockout cực trị làm tổng demand tăng quá mức. Công thức triển khai là:

$$\text{lost}_t = \max\left(\frac{\hat{y}_t^{\text{raw}}}{c} - y_t^{\text{obs}}, 0\right), \quad \text{lost}_t^{\text{cap}} = \min(\text{lost}_t, q90), \quad y_t^{\text{rec}} = y_t^{\text{obs}} + \text{lost}_t^{\text{cap}}.$$

0.5.5 Daily forecasting target

Sau recovery hourly, dữ liệu được aggregate lên daily. Target chính là `target_next7_recovered_daily`, tức tổng recovered demand trong 7 ngày sau forecast origin. Target dạng tổng 7 ngày phù hợp với bài toán replenishment hơn forecast từng giờ riêng lẻ vì quyết định nhập hàng thường dựa trên nhu cầu vài ngày tới.

0.5.6 Modeling choice

LightGBM được chọn vì đây là bài toán tabular time-series quy mô lớn với nhiều feature lag, rolling, calendar, stockout, promotion và weather. Classical ARIMA/SARIMA không được chọn làm model chính vì khó scale tới hàng nghìn chuỗi store-product và khó xử lý chuỗi thưa. Deep learning không phải trọng tâm vì yêu cầu tuning/tài nguyên cao hơn, trong khi mục tiêu đề án là một pipeline có thể giải thích và tái lập.

0.5.7 Baselines và hybrid

Báo cáo không chỉ so sánh hai mô hình ML. Các baseline daily gồm naive x7, seasonal naive 7-day và rolling mean 14-day. Seasonal naive 7-day rất mạnh do dữ liệu có seasonality tuần rõ. Vì vậy, mô hình cuối là hybrid seasonal-ML: blend giữa seasonal naive 7-day và recovered-demand LightGBM, với trọng số chọn trên validation set.

0.6 Latent demand recovery và kiểm soát imputation

0.6.1 Kết quả recovery tổng quan

Bảng sau tóm tắt kết quả recovery. Recovered demand tăng khoảng 10.68% so với observed sales. Về business, con số này có thể hiểu là phần demand tiềm ẩn mà observed sales không phản ánh đầy đủ do stockout.

Table 9: Tóm tắt latent demand recovery

Metric	Value
Observed sales	482697.09375
Recovered latent demand	534270.1875
Recovered lost demand	51572.875
Recovered lift over observed	0.10684314370155334
Stockout row rate	0.24652109375
Recovery method	expanding-window weekly recovery
Imputation calibration factor	1.1297638401922185
Lost demand cap quantile	q90 of calibrated positive lost demand
Lost demand cap value	0.06627678871154785
Warmup days kept observed	14
Recovery block days	7
Recovery blocks	9
Final recovery train rows	400000
Recovery train source	past non-stockout rows only for train blocks; train-period non-stockout rows for validation/test
Final recovery train end	2024-06-10 23:00:00
Validation start	2024-06-11 00:00:00
Test start	2024-06-18 00:00:00




Figure 18: Observed sales và recovered demand theo thời gian.

0.6.2 Uplift do imputation

Vì recovered demand không phải ground truth thật, báo cáo không dùng imputation một cách mù quáng. Uplift được kiểm tra ở nhiều cấp: tổng dataset, từng ngày và từng series. Nếu uplift quá lớn hoặc tập trung ở một số series, kết quả forecast sẽ phụ thuộc quá mạnh vào imputation.

Table 10: Tổng mức uplift do imputation

Metric	Value
Observed sales	482,697
Recovered demand	534,270
Recovered lost demand	51,573
Recovered lift over observed	0.1068
Raw calibrated lost demand before cap	65,368
Cap retained share of raw lost demand	0.7890
Stockout row share	0.2465
Recovered lost demand from stockout rows	51,573
Mean stockout uplift per stockout row	0.0182




Figure 19: Observed sales, recovered demand và recovered lost demand theo ngày.

0.6.3 Pseudo-stockout validation

Pseudo-stockout validation lấy các dòng non-stockout trong validation period, giả sử chúng cần impute, rồi so sánh prediction của recovery model với observed sales thật. Row-level hourly validation có WAPE cao vì hourly sales rất thưa và nhiều giá trị nhỏ. Do đó, báo cáo bổ sung aggregate validation, phù hợp hơn với mục tiêu forecast daily demand.

Table 11: Pseudo-stockout validation ở cấp row hourly

Metric	Value
Validation rows	300000
Pseudo-stockout source	non-stockout rows from validation period
RMSE	0.10030610859394073
MAE	0.05774029344320297
WAPE	1.0391554832458496
sMAPE	1.6277295807119518
Mean prediction / actual ratio	1.1315665245056152
Mean error actual-minus-imputed	-0.007310444954782724

Table 12: Pseudo-stockout validation ở các cấp aggregate

Validation level	RMSE	MAE	WAPE	sMAPE	Prediction / actual ratio	N
Hourly aggregate	42.5877	21.9068	0.2208	0.2237	1.1316	168
Daily aggregate	450.9920	416.6911	0.1750	0.1677	1.1316	7
Series daily aggregate	0.3245	0.2155	0.4384	0.6309	1.1316	33907

0.6.4 Sensitivity theo cap

Cap q90 được chọn như một điểm cân bằng. Cap q75 bảo thủ hơn nhưng có thể under-recover; q100 giữ toàn bộ raw lost demand nhưng dễ phụ thuộc mạnh vào outlier. Sensitivity giúp chứng minh kết luận không chỉ dựa trên một lựa chọn cap tùy tiện.

Table 13: Sensitivity theo mức cap lost demand

Scenario	Cap value	Recovered demand	Recovered lost demand	Recovered lift over observed	Share of original recovered lost demand
Cap lost-demand at q50	0.0151	505,963	23,266	0.0482	0.3559
Cap lost-demand at q75	0.0369	523,781	41,084	0.0851	0.6285
Cap lost-demand at q90	0.0663	534,270	51,573	0.1068	0.7890
Cap lost-demand at q100	2.7508	548,064	65,368	0.1354	1.0000




Figure 20: Phân phối recovered lift ở cấp series.




Figure 21: Top series có lift cao nhất.

0.7 Forecasting results

0.7.1 So sánh không impute và có impute

So sánh quan trọng nhất là giữa observed-sales forecasting và recovered-demand forecasting. Observed-sales LightGBM đại diện cho hướng không xử lý stockout trong target. Recovered-demand LightGBM đại diện cho hướng có recovery/imputation. Khi đánh giá trên recovered latent demand proxy, WAPE giảm từ 24.42% xuống 20.28%. Điều này cho thấy stockout-aware recovery giúp giảm under-forecast.

Table 14: So sánh mô hình/baseline trên recovered latent demand proxy

Model	Training target	Evaluation target	RMSE	MAE	WAPE	sMAPE	WPE	N
Recovered naive x7	baseline_no_training	Recovered latent demand proxy	4.3949	2.8080	0.3149	0.3870	-0.0198	70000
Recovered seasonal naive 7-day	baseline_no_training	Recovered latent demand proxy	2.9113	1.7704	0.1985	0.2269	-0.0614	70000
Recovered rolling mean 14-day	baseline_no_training	Recovered latent demand proxy	3.1099	1.8367	0.2060	0.2268	-0.0807	70000
Observed-sales forecasting	target_next7_observed_daily	Recovered latent demand proxy	3.6749	2.1780	0.2442	0.2755	-0.1788	70000
Observed-sales forecasting	target_next7_observed_daily	Observed sales	3.2644	1.7730	0.2206	0.2412	-0.0887	70000
Recovered-demand forecasting	target_next7_recovered_daily	Recovered latent demand proxy	3.6160	1.8082	0.2028	0.2135	-0.0800	70000
Recovered-demand forecasting	target_next7_recovered_daily	Observed sales	3.4820	1.7713	0.2204	0.2459	0.0209	70000
Recovered seasonal-ML hybrid	seasonal_naive_plus_recovered_lightgbm_alpha_0.60	Recovered latent demand proxy	3.2106	1.7545	0.1967	0.2127	-0.0726	70000




Figure 22: Forecast tổng nhu cầu 7 ngày.




Figure 23: WAPE của các mô hình/baseline trên recovered latent demand proxy.

0.7.2 Seasonal naive là baseline mạnh

Seasonal naive 7-day đạt WAPE 19.85%, tốt hơn recovered-demand LightGBM thuần. Đây không phải thất bại của ML mà là insight quan trọng: pattern tuần là thành phần nền rất mạnh.

Một mô hình tốt trong bài toán này cần tôn trọng seasonality thay vì cố học lại hoàn toàn từ đầu.

0.7.3 Hybrid seasonal-ML

Hybrid seasonal-ML blend seasonal naive 7-day với recovered-demand LightGBM. Trọng số LightGBM được chọn trên validation set, không chọn bằng test. Trọng số tốt nhất hiện tại là 0.60 cho LightGBM và 0.40 cho seasonal naive. Kết quả test đạt WAPE 19.67%, tốt nhất trong nhóm đã thử.

Table 15: Chọn trọng số hybrid trên validation

LightGBM weight	Seasonal naive weight	Validation WAPE
0.6000	0.4000	0.1901
0.5500	0.4500	0.1901
0.6500	0.3500	0.1902
0.5000	0.5000	0.1903
0.7000	0.3000	0.1903
0.4500	0.5500	0.1906
0.7500	0.2500	0.1906
0.4000	0.6000	0.1909
0.8000	0.2000	0.1909
0.3500	0.6500	0.1914

0.7.4 Business interpretation

Ý nghĩa của kết quả không chỉ là giảm WAPE. Nếu doanh nghiệp forecast observed sales, model có thể tiếp tục đánh giá thấp nhu cầu ở các SKU hay hết hàng. Recovery làm rõ phần demand bị ẩn, còn seasonal baseline cho thấy lịch tuần là thông tin vận hành rất quan trọng. Hybrid cuối cùng kết hợp cả hai: demand correction và weekly seasonality.

0.7.5 Feature importance

Feature importance của recovered-demand LightGBM cho thấy các lag và rolling features của recovered demand, cùng với stockout rate, là các tín hiệu quan trọng. Điều này phù hợp với trực giác: demand tương lai phụ thuộc mạnh vào mức nền gần đây, pattern tuần và mức độ kiểm duyệt bởi tồn kho.

Table 16: Feature importance của recovered-demand LightGBM

feature	importance
stockout_rate	986
recovered_daily_lag_28	969
recovered_daily_lag_1	820
recovered_daily_lag_14	814
recovered_daily_lag_7	794
recovered_daily_lag_2	699
recovered_daily_roll_mean_28	671
recovered_daily_roll_sum_28	585
day_of_week	518
recovered_daily_roll_mean_7	490
month	410
recovered_daily_roll_mean_14	392
recovered_daily_roll_sum_14	329
recovered_daily_roll_sum_7	289
is_weekend	23




Figure 24: Top 20 feature importance.

0.8 Diagnostics và forecast uncertainty

0.8.1 Residual diagnostics

Diagnostics được thực hiện trên recovered latent demand proxy. Với target là tổng 7 ngày tiếp theo, các forecast origin liên tiếp có target window overlap mạnh: forecast tại ngày t và ngày $t + 1$ chia sẻ 6/7 ngày trong target. Vì vậy, residual rolling evaluation có thể còn autocorrelation một phần do thiết kế target, không nhất thiết chỉ do model thiếu pattern.

Table 17: Diagnostics trên recovered latent demand proxy

Model	RMSE	MAE	WAPE	WPE	Residual mean	Residual std	Ljung-Box p-value	Jarque-Bera p-value	N
Recovered naive x7	4.3949	2.8080	0.3149	-0.0198	0.1770	4.3913	0.1790	0.0000	70000
Recovered seasonal naive 7-day	2.9113	1.7704	0.1985	-0.0614	0.5475	2.8594	0.0131	0.0000	70000
Recovered rolling mean 14-day	3.1099	1.8367	0.2060	-0.0807	0.7194	3.0255	0.0001	0.0000	70000
Observed-sales forecasting	3.6749	2.1780	0.2442	-0.1788	1.5943	3.3111	0.0127	0.0000	70000
Recovered-demand forecasting	3.6160	1.8082	0.2028	-0.0800	0.7134	3.5450	0.0665	0.0000	70000
Recovered seasonal-ML hybrid	3.2106	1.7545	0.1967	-0.0726	0.6470	3.1448	0.0311	0.0000	70000




Figure 25: Phân phối residual của mô hình chính.




Figure 26: Residual ACF của mô hình chính.

0.8.2 Non-overlap diagnostics

Báo cáo bổ sung non-overlap diagnostics bằng cách lấy forecast origin cách nhau 7 ngày. Kiểm tra này công bằng hơn với target next-7-day, nhưng test window chỉ có 14 ngày nên chỉ có rất ít aggregate points. Vì vậy, đây là sanity check phụ, không phải bằng chứng tuyệt đối rằng residual độc lập hoàn toàn.

Table 18: Diagnostics trên non-overlapping 7-day targets

Model	Evaluation dates	RMSE	MAE	WAPE	WPE	Ljung-Box p-value	N	Aggregate residual points
Recovered naive x7	2024-06-11; 2024-06-18	4.6707	2.9483	0.3389	0.0080	0.1573	10000	2
Recovered seasonal naive 7-day	2024-06-11; 2024-06-18	2.8150	1.7140	0.1970	-0.0662	0.1573	10000	2
Recovered rolling mean 14-day	2024-06-11; 2024-06-18	3.0150	1.7821	0.2049	-0.0738	0.1573	10000	2
Observed-sales forecasting	2024-06-11; 2024-06-18	3.5320	2.1044	0.2419	-0.1753	0.1573	10000	2
Recovered-demand forecasting	2024-06-11; 2024-06-18	3.3906	1.7544	0.2017	-0.0716	0.1573	10000	2
Recovered seasonal-ML hybrid	2024-06-11; 2024-06-18	3.0564	1.7001	0.1954	-0.0695	0.1573	10000	2

0.8.3 Prediction intervals

Khoảng dự báo được xây dựng từ phân vị residual validation. Cách này không giả định residual chuẩn tuyệt đối, phù hợp hơn với dữ liệu bán lẻ thưa và nhiều spike.




Figure 27: Khoảng dự báo 80\{\}\% và 95\{\}\% cho mô hình chính.

0.9 Business insights

0.9.1 Insight 1: Stockout làm sai lệch tín hiệu demand

Tỷ lệ stockout row khoảng 24.65% cho thấy đây không phải hiện tượng hiếm. Nếu doanh nghiệp chỉ quan sát sales, một phần demand bị ẩn sẽ bị hiểu nhầm là demand thấp. Trong vận hành tồn kho, đây là vấn đề nghiêm trọng vì forecast thấp dẫn tới reorder thấp.

0.9.2 Insight 2: Latent demand recovery cho biết mức demand bị bỏ lỡ

Recovered demand tăng khoảng 10.68% so với observed sales. Con số này không nên hiểu là doanh nghiệp chắc chắn mất đúng từng đó doanh số, vì recovered demand là proxy. Tuy nhiên, nó là chỉ báo hữu ích: observed sales có khả năng đang understated demand ở mức đáng kể.

0.9.3 Insight 3: Weekly seasonality là baseline nghiệp vụ mạnh

Seasonal naive 7-day rất mạnh. Về business, điều này nghĩa là nhu cầu trong bán lẻ có lịch tuần rõ ràng. Khi triển khai hệ thống forecast, không nên bỏ qua các quy tắc đơn giản như lấy demand cùng kỳ tuần trước. ML chỉ có ý nghĩa khi nó cải thiện trên nền seasonality mạnh đó hoặc kết hợp tốt với nó.

0.9.4 Insight 4: Model cuối nên hỗ trợ replenishment

Mục tiêu cuối không phải tạo model có metric đẹp nhất trong phòng thí nghiệm, mà là hỗ trợ quyết định nhập hàng. Forecast recovered demand phù hợp hơn observed sales vì nó hướng tới

nhu cầu vận hành. Hybrid seasonal-ML có thể xem là một forecast thực dụng: dùng seasonality làm nền, dùng ML để hiệu chỉnh theo stockout và pattern gần đây.

0.9.5 Khuyến nghị triển khai

Nếu triển khai thực tế, hệ thống nên báo cáo song song observed sales forecast và recovered demand forecast. Khi hai giá trị lệch nhau lớn ở các SKU có stockout cao, đây là tín hiệu cần kiểm tra replenishment. Doanh nghiệp cũng nên theo dõi uplift do imputation theo SKU/store để phát hiện nhóm sản phẩm có rủi ro mất doanh số do hết hàng.

0.10 Kết luận, hạn chế và hướng phát triển

0.10.1 Kết luận

Báo cáo cho thấy bài toán forecasting trên FreshRetailNet-50K nên được framing như bài toán stockout-aware demand forecasting thay vì raw sales forecasting. Khi không xử lý stockout, observed-sales LightGBM đạt WAPE 24.42%. Sau khi recover latent demand và train trên recovered demand, WAPE giảm xuống 20.28%. Seasonal naive 7-day là baseline mạnh với WAPE 19.85%. Mô hình cuối hybrid seasonal-ML đạt WAPE 19.67%.

Kết quả này có hai thông điệp chính. Thứ nhất, xử lý stockout là cần thiết vì observed sales có thể understates demand. Thứ hai, seasonality tuần là pattern nền cực mạnh; một mô hình forecasting tốt nên kết hợp seasonality này thay vì bỏ qua.

0.10.2 Hạn chế

Recovered demand vẫn là proxy được ước lượng, không phải ground truth demand thật. Imputation ở cấp hourly row-level nhiều vì dữ liệu thưa và nhiều zero. Test window chỉ kéo dài 14 ngày nên diagnostics non-overlap còn ít điểm. Ngoài ra, báo cáo chưa trực tiếp tối ưu inventory policy như safety stock, reorder point, service level hoặc lost-sales cost.

0.10.3 Hướng phát triển

Nếu có thêm thời gian, hướng phát triển đầu tiên là kiểm tra pipeline trên nhiều sample hoặc full data. Hướng thứ hai là thử các mô hình imputation chuyên biệt như SAITS, TimesNet hoặc DLinear ở quy mô nhỏ để so sánh với LightGBM recovery. Hướng thứ ba là chuyển từ forecast accuracy sang inventory impact: service level, fill rate, lost sales và holding cost. Đây là bước quan trọng để biến forecast thành quyết định vận hành.

.1 Phụ lục A: Bảng hỗ trợ trực tiếp

Phụ lục chỉ giữ các bảng hỗ trợ trực tiếp cho contribution chính: recovery không leakage, kiểm soát imputation, diagnostics phụ và khả năng tái lập. Các benchmark observed-sales hourly, ablation cũ, SARIMAX aggregate và các bảng thử nghiệm phụ được giữ trong thư mục archive_auxiliary/ thay vì đưa vào báo cáo chính, để tránh làm loãng câu chuyện.

Table 19: Các block expanding-window dùng cho recovery

Block start	Block end	Training end	Training rows	Predicted rows
2024-04-11	2024-04-18	2024-04-10 23:00:00	400000	840000
2024-04-18	2024-04-25	2024-04-17 23:00:00	400000	840000
2024-04-25	2024-05-02	2024-04-24 23:00:00	400000	840000
2024-05-02	2024-05-09	2024-05-01 23:00:00	400000	840000
2024-05-09	2024-05-16	2024-05-08 23:00:00	400000	840000
2024-05-16	2024-05-23	2024-05-15 23:00:00	400000	840000
2024-05-23	2024-05-30	2024-05-22 23:00:00	400000	840000
2024-05-30	2024-06-06	2024-05-29 23:00:00	400000	840000
2024-06-06	2024-06-11	2024-06-05 23:00:00	400000	600000

Table 20: Top series theo recovered lift

series_id	observed_sales	recovered_demand	recovered_lost_demand	stockout_rate	Recovered lift over observed	Recovered share from imputation
0_554_90	39.3000	72.3776	33.0776	0.7339	0.8417	0.4570
0_597_41	39.8500	71.9541	32.1041	0.6150	0.8056	0.4462
3_724_188	45.3000	76.9671	31.6671	0.7248	0.6991	0.4114
4_356_90	39.0500	66.2217	27.1717	0.6029	0.6958	0.4103
11_533_129	43.7000	72.7158	29.0158	0.7161	0.6640	0.3990
6_493_129	44.2000	73.4980	29.2980	0.7357	0.6629	0.3986
0_173_90	55.3000	91.7408	36.4408	0.6536	0.6590	0.3972
5_6_757	44.5000	72.8119	28.3119	0.7448	0.6362	0.3888
12_228_129	45.7000	74.0857	28.3857	0.6667	0.6211	0.3831
3_835_333	46.7000	74.9063	28.2063	0.6944	0.6040	0.3766
6_369_757	43.9600	70.2874	26.3274	0.5894	0.5989	0.3746
0_78_129	52.3000	82.0192	29.7192	0.6215	0.5682	0.3623
12_603_129	44.2000	68.9360	24.7360	0.6211	0.5596	0.3588
0_185_129	48.9000	75.3529	26.4529	0.5694	0.5410	0.3511
0_850_90	55.7700	84.9366	29.1666	0.5608	0.5230	0.3434
12_230_822	39.2100	59.6896	20.4796	0.5838	0.5223	0.3431
3_809_129	42.0000	63.7762	21.7762	0.5764	0.5185	0.3414
1_123_73	44.5000	67.2866	22.7866	0.5994	0.5121	0.3387
3_766_44	43.2800	65.0652	21.7852	0.5321	0.5034	0.3348
12_390_757	47.5300	71.3705	23.8405	0.6519	0.5016	0.3340
3_857_188	40.1100	59.9977	19.8877	0.4991	0.4958	0.3315
12_313_41	41.2200	61.6574	20.4374	0.4891	0.4958	0.3315
3_110_315	42.0000	62.7786	20.7786	0.5569	0.4947	0.3310
0_190_41	46.3700	69.1925	22.8225	0.4497	0.4922	0.3298
0_243_26	41.3400	61.4942	20.1542	0.6042	0.4875	0.3277

Table 21: Diagnostics phụ trên non-overlapping target

Model	Evaluation dates	RMSE	MAE	WAPE	WPE	Ljung-Box p-value	N	Aggregate residual points
Recovered naive x7	2024-06-11; 2024-06-18	4.6707	2.9483	0.3389	0.0080	0.1573	10000	2
Recovered seasonal naive 7-day	2024-06-11; 2024-06-18	2.8150	1.7140	0.1970	-0.0662	0.1573	10000	2
Recovered rolling mean 14-day	2024-06-11; 2024-06-18	3.0150	1.7821	0.2049	-0.0738	0.1573	10000	2
Observed-sales forecasting	2024-06-11; 2024-06-18	3.5320	2.1044	0.2419	-0.1753	0.1573	10000	2
Recovered-demand forecasting	2024-06-11; 2024-06-18	3.3906	1.7544	0.2017	-0.0716	0.1573	10000	2
Recovered seasonal-ML hybrid	2024-06-11; 2024-06-18	3.0564	1.7001	0.1954	-0.0695	0.1573	10000	2

.2 Phụ lục B: Reproducibility

Pipeline chính có thể chạy bằng:

```
pip install -r requirements.txt  
python main_pipeline.py
```

Các output chính nằm trong deliverables/ và outputs/. Dữ liệu raw cần đặt trong data/raw/. Random seed được cố định là 42 trong các mô hình LightGBM và các bước sampling.